

DOCUMENTO TÉCNICO

Construcción de un Entorno Analítico · SalesHealth

Gestión de Bases de Datos · 3º Ingeniería Matemática · UAX 2025/2026

Pablo Jiménez Girardeau

3º Ingeniería Matemática · UAX
Gestión de Bases de Datos · Curso 2025/2026

RESUMEN EJECUTIVO

71.935 registros integrados desde 4 sistemas	44 tablas en 4 schemas (BD única)	21/21 validaciones automáticas OK
5.750 clientes segmentados en 3 clusters	K-Means K=3 Silhouette Score 0,847	Dashboard HTML 10 páginas interactivas

1. Arquitectura del Entorno Analítico

El proyecto implementa un entorno analítico completo sobre una única base de datos PostgreSQL 18 (saleshealth), organizada en cuatro schemas. Se optó por una arquitectura de schemas en lugar de dos bases de datos separadas: permite JOINS directos entre capas sin dblink, simplifica la gestión de credenciales en el ETL y mantiene el aislamiento lógico entre etapas.

Schema	Función	Tablas
public	Datos operacionales origen (OLTP)	17
stg	Staging — copia exacta sin transformaciones	17
dwh	Data Warehouse dimensional — esquema estrella Kimball	9
marts	Capa analítica — métricas precalculadas por cliente	1

El flujo sigue la arquitectura Data Lake → Staging → DWH → Data Mart. Los sistemas de origen son ERP (ventas, productos, tiendas), CRM (clientes), Logística (inventario) y Postventa (devoluciones), integrando un total de 71.935 registros operacionales.

2. Modelo Dimensional — Esquema Estrella Kimball

Metodología Kimball. Grano: 1 fila = 1 línea de venta (sale_item). El modelo incluye 2 tablas de hechos y 7 dimensiones.

2.1 Tablas de hechos

Tabla	Grano	Registros	Métricas principales
fact_ventas	1 línea de venta	42.555	cantidad, precio_unitario, subtotal_bruto, coste_total, margen_bruto, margen_pct, subtotal_neto, es_devuelta
fact_devoluciones	1 devolución	2.292	cantidad_devuelta, importe_devuelto, coste_devuelto

2.2 Dimensiones

Dimensión	Fuente	Reg.	Campos clave
dim_fecha	Generada	2.191	fecha_sk (YYYYMMDD), anio, trimestre, mes, dia_semana
dim_cliente	customer	5.751	cliente_sk, cliente_nk, nombre, email, fecha_alta
dim_producto	product + central_product + brand + category	51	nombre, categoria, marca, precio_venta, coste_unitario, margen_pct
dim_tienda	store	21	nombre, ciudad, codigo_postal, latitud, longitud
dim_zona	city_zone	43	codigo_postal (NK), distrito, tipo_area, orientacion
dim_oferta	offer	2	nombre, descuento_pct, fecha_inicio, fecha_fin
dim_motivo_devolucion	return_reason	7	motivo, activo, es_desconocido

2.3 Decisiones de diseño clave

- **dim_zona como dimensión independiente** → análisis geográfico desacoplado del cliente (customer no tiene FK a city_zone).
- **Flag es_devuelta en fact_ventas** → permite calcular subtotal_neto sin JOIN adicional a fact_devoluciones.
- **Registro Desconocido SK=1 en todas las dimensiones** → 0 NULLs en tablas de hechos, integridad referencial total.
- **Flag coste_imputado en dim_producto** → trazabilidad del producto 29 (precio corregido P06).
- **Zona geográfica resuelta via store.postal_code** → customer no tiene FK a city_zone.

3. Pipeline ETL

Pipeline idempotente: cada ejecución comienza con TRUNCATE CASCADE sobre hechos y dimensiones. Tiempo total ~18 segundos. Comando: `python -m etl.run_etl`.

Fase	Módulo	Función	Tiempo
1 — Extract	extract.py	Copia 17 tablas public.* → stg.* sin transformaciones	~0.8s
2 — Dimensiones	load_dimensions.py	Genera 7 dimensiones con SKs, NKs y registros desconocido	~0.4s
3 — Hechos	load_facts.py	Carga fact_ventas y fact_devoluciones	~1.9s

		resolviendo todas las SKs	
4 — Validaciones	validate.py	21 validaciones automáticas declarativas (V01-V21)	~0.1s
5 — Customer 360	customer_360.py	Calcula CLTV, AOV y Return Rate por cliente en marts	~0.2s
6 — Clustering	clusters.py	PCA (2 componentes) + K-Means K=3 → asigna segmento a cada cliente	~14.8s

3.1 Validaciones automáticas — 21/21 OK

- **V01-V04:** Conteos staging: sale 20.000 | sale_item 42.555 | customer 5.750 | product 50.
- **V05-V10:** Conteos dimensiones con registros desconocido incluidos.
- **V11-V12:** Conteos hechos: fact_ventas 42.555 | fact_devoluciones > 0.
- **V13-V16:** Integridad referencial — 0 FKs huérfanas en fact_ventas.
- **V17-V21:** Rangos numéricos sin anomalías, 0 márgenes negativos, total DWH coincide con staging (diferencia < 1€).

4. Métricas de Cliente

Todas las métricas se calculan en customer_360.py y se persisten en marts.customer_360 (5.750 filas, una por cliente), evitando consultas complejas en tiempo real.

4.1 CLTV (Customer Lifetime Value)

Equivalencia algebraica con la fórmula del enunciado $CLTV = \text{Ingresos} \times \text{Margen} \times \text{Frecuencia} \times R$:

```
AOV × (num_ventas / meses_activo) × meses_activo × (margen_pct/100)
= (ingresos_netos / num_ventas) × num_ventas × (margen_pct/100)
= GREATEST( ingresos_netos × (margen_pct / 100), 0 ) ← simplificación exacta
```

GREATEST(..., 0) capea a cero los 17 clientes (0,30%) con margen neto negativo por devoluciones excesivas.

4.2 AOV, Return Rate y Frecuencia mensual

Métrica	Fórmula implementada	Nota
AOV	$\text{ingresos_netos} / \text{num_ventas}$	Ticket medio neto por pedido
Return Rate	$\text{LEAST}(\text{unidades_devueltas} / \text{unidades_compradas} \times 100, 100)$	Capeado a 100% — evita anomalías por doble registro
Frecuencia mensual	$\text{num_ventas} / \text{GREATEST}((\text{ultima_compra} - \text{primera_compra}) / 30, 1)$	Denominador mínimo 1 mes — evita división por cero
Margen % medio	$\text{margen_bruto} / \text{ingresos_brutos} \times 100$	$\text{margen_bruto} = \text{SUM}(\text{subtotal_bruto}) - \text{SUM}(\text{coste_total})$

4.3 Resultados principales

KPI	Valor
Clientes analizados	5.750
CLTV total · medio · mediana	€3,7M · €643 · €52
AOV medio	€118
Return Rate global	2,85%

Ingresos perdidos por devoluciones	€271.811
% clientes que genera el 80% del CLTV	8,4% (483 clientes)

5. PCA y Clustering de Clientes

La segmentación forma parte del pipeline ETL (clusters.py). Se aplica StandardScaler → PCA (2 componentes, random_state=42) → K-Means (K=3, n_init=10) sobre el espacio reducido. Los clusters se etiquetan por CLTV medio descendente.

Features: *cltv · ingresos_netos · aov · frecuencia_mensual · recencia_dias · return_rate · antigüedad_dias*

Varianza explicada: PC1=66,1% + PC2=14,7% = 80,8% total. Silhouette Score K=3 = 0,847.

Segmento	Clientes	% Total	CLTV medio	Perfil
Champions	750	13,0%	€4.512	20 ventas medias · baja recencia · Return Rate 2,5%
Base	4.589	79,8%	€67	1 venta · baja recencia · clientes con única compra
Churned	411	7,1%	€10	1 venta · Return Rate 86,5% · margen neto nulo por devoluciones

Nota: el CLTV capeado a 0 redujo la varianza de los clientes de menor valor, colapsando los 4 grupos teóricos en 3 efectivos.

5.1 Acciones recomendadas por segmento

- **Champions (13%):** Programa VIP, acceso anticipado a nuevos productos y campaña de referidos. Atención personalizada prioritaria.
- **Base (80%):** Campaña de reactivación con incentivo de segunda compra. Objetivo: aumentar frecuencia mensual.
- **Churned (7%):** Evaluar coste vs. beneficio. Descuento agresivo de recuperación o baja definitiva según recencia.

6. Calidad de Datos — Correcciones Aplicadas

Se identificaron 10 problemas (P01-P10). Los 3 con impacto numérico se corrigieron antes del ETL; los 7 restantes se documentaron sin modificación por regla de negocio.

ID	Tabla	Problema	Corrección aplicada
P06	product	product_id=29: precio €19,99 con coste €59,94 (margen -199,85%). Categoría 1 tiene margen fijo 40%.	price = 59,94 / 0,60 = €99,90. Flag coste_imputado=TRUE en dim_producto.
P07	sale_item	8 líneas: subtotal ≠ quantity × unit_price. Diferencia total -€46,96.	UPDATE subtotal = ROUND(quantity × unit_price, 2). Los ítems son fuente de verdad.
P08	sale	6 ventas: total ≠ SUM(sale_item.subtotal).	UPDATE total desde suma de líneas (ejecutado después de P07).

Los 7 problemas restantes (emails malformados, teléfonos incorrectos, nombres duplicados, opened_date no fiable, offer_id 99,98% NULL) se documentan y conservan por regla de negocio: nunca eliminar clientes.

7. Hallazgos Clave del Análisis

- **Concentración extrema de valor:** El 8,4% de clientes (483) genera el 80% del CLTV. Mediana €52 frente a media €643 — cola larga de alto valor.
- **Champions generan el 91,6% del CLTV:** Solo 750 clientes (13%) concentran prácticamente todo el valor del negocio.
- **Return Rate muy sano:** 2,85% global (mediana 1,3%). Solo 301 clientes (5,2%) superan el 50% de devoluciones. Impacto: €271.811.
- **Correlaciones predictivas del CLTV:** $\text{CLTV} \leftrightarrow \text{ingresos_netos} = 0,97$. $\text{CLTV} \leftrightarrow \text{num_ventas} = 0,94$. El número de pedidos es el predictor más potente.
- **Distribución bimodal de compras:** La mayoría de clientes compra una sola vez o más de 10 veces, sin término medio. Refuerza la necesidad de programas de segunda compra.
- **Cohort 2020 acumula el mayor CLTV histórico:** CLTV medio ~€4.800 frente a ~€62 en cohorts recientes — efecto esperado de la fórmula que incorpora antigüedad acumulada.

8. Decisiones Técnicas Clave

ID	Ámbito	Decisión	Justificación
D01	Arquitectura	Una BD con 4 schemas	JOINS directos entre capas sin dblink
D02	Calidad	Nunca eliminar clientes	Regla de negocio establecida
D03	ETL	Idempotencia — TRUNCATE CASCADE	N ejecuciones, resultados idénticos
D04	DWH	Registro Desconocido (SK=1) en dims	0 NULLs en tablas de hechos
D05	DWH	dim_zona independiente	Análisis geográfico desacoplado del cliente
D06	DWH	Flag es_devuelta en fact_ventas	CLTV neto sin JOIN adicional
D07	Métricas	$\text{CLTV} = \text{ingresos_netos} \times (\text{margen}/100)$	Simplificación algebraica exacta del enunciado
D08	ML	CLTV capeado — $\text{GREATEST}(\dots, 0)$	17 clientes con margen neto negativo
D09	ML	K-Means sobre espacio PCA 2D	Reduce ruido y mejora separabilidad
D10	Zona	Zona via store.postal_code	customer no tiene FK a city_zone